

Naiwny klasyfikator bayesowski

Szymon Głab

27 marca 2023

Warunkowe prawdopodobieństwo

Prawdopodobieństwo zdarzenia A przy założeniu, że zachodzi B wynosi:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Warunkowe prawdopodobieństwo

Prawdopodobieństwo zdarzenia A przy założeniu, że zachodzi B wynosi:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

	Mężczyzna	Kobieta	Razem
zaszczepieni	32	48	80
nie zaszczepieni	8	12	20
W sumie	40	60	100

Warunkowe prawdopodobieństwo

Prawdopodobieństwo zdarzenia A przy założeniu, że zachodzi B wynosi:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

	Mężczyzna	Kobieta	Razem
zaszczepieni	32	48	80
nie zaszczepieni	8	12	20
W sumie	40	60	100

$$P(\text{Zaszczepiony} | \text{Mężczyzna}) =$$

Warunkowe prawdopodobieństwo

Prawdopodobieństwo zdarzenia A przy założeniu, że zachodzi B wynosi:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

	Mężczyzna	Kobieta	Razem
zaszczepieni	32	48	80
nie zaszczepieni	8	12	20
W sumie	40	60	100

$$P(\text{Zaszczepiony}|\text{Mężczyzna}) = \frac{P(Z \cap M)}{P(M)} =$$

Warunkowe prawdopodobieństwo

Prawdopodobieństwo zdarzenia A przy założeniu, że zachodzi B wynosi:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

	Mężczyzna	Kobieta	Razem
zaszczepieni	32	48	80
nie zaszczepieni	8	12	20
W sumie	40	60	100

$$P(\text{Zaszczepiony}|\text{Mężczyzna}) = \frac{P(Z \cap M)}{P(M)} = \frac{\frac{32}{100}}{\frac{40}{100}} =$$

Warunkowe prawdopodobieństwo

Prawdopodobieństwo zdarzenia A przy założeniu, że zachodzi B wynosi:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

	Mężczyzna	Kobieta	Razem
zaszczepieni	32	48	80
nie zaszczepieni	8	12	20
W sumie	40	60	100

$$P(\text{Zaszczepiony}|\text{Mężczyzna}) = \frac{P(Z \cap M)}{P(M)} = \frac{\frac{32}{100}}{\frac{40}{100}} = 0.8$$

Warunkowe prawdopodobieństwo

Prawdopodobieństwo zdarzenia A przy założeniu, że zachodzi B wynosi:


$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

	Mężczyzna	Kobieta	Razem
zaszczepieni	32	48	80
nie zaszczepieni	8	12	20
W sumie	40	60	100

$$P(\text{Zaszczepiony}|\text{Mężczyzna}) = \frac{P(Z \cap M)}{P(M)} = \frac{\frac{32}{100}}{\frac{40}{100}} = 0.8$$

$$P(\text{Zaszczepiony}|\text{Mężczyzna}) = P(\text{Zaszczepiony})$$

Monty Hall Problem



<https://www.youtube.com/watch?v=4Lb-6rxZxx0>

Proste przekształcenia

Twierdzenie Bayesa

Proste przekształcenia

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad \text{oraz} \quad P(B|A) = \frac{P(B \cap A)}{P(A)}$$

Twierdzenie Bayesa

Proste przekształcenia

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad \text{oraz} \quad P(B|A) = \frac{P(B \cap A)}{P(A)}$$

$$P(A \cap B)$$

Twierdzenie Bayesa

Proste przekształcenia

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad \text{oraz} \quad P(B|A) = \frac{P(B \cap A)}{P(A)}$$

$$P(A \cap B) = P(B|A)P(A)$$

Twierdzenie Bayesa

Proste przekształcenia


$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad \text{oraz} \quad P(B|A) = \frac{P(B \cap A)}{P(A)}$$

$$P(A \cap B) = P(B|A)P(A)$$


Twierdzenie Bayesa

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Twierdzenie Bayesa. Przykład




Twierdzenie Bayesa. Przykład



Założmy, że losowo wybranej osobie z badanej grupy udaje się rozwiązać problem. Czy raczej mężczyzna czy kobieta?


Twierdzenie Bayesa. Przykład



Założmy, że losowo wybranej osobie z badanej grupy udaje się rozwiązać problem. Czy raczej mężczyzna czy kobieta?

$$P(M|S) =$$


Twierdzenie Bayesa. Przykład



Założmy, że losowo wybranej osobie z badanej grupy udaje się rozwiązać problem. Czy raczej mężczyzna czy kobieta?

$$P(M|S) = \frac{P(S|M)P(M)}{P(S)} =$$


Twierdzenie Bayesa. Przykład



Założmy, że losowo wybranej osobie z badanej grupy udaje się rozwiązać problem. Czy raczej mężczyzna czy kobieta?

$$P(M|S) = \frac{P(S|M)P(M)}{P(S)} = \frac{0.6 \times 0.6}{P(S)} =$$


Twierdzenie Bayesa. Przykład



Założmy, że losowo wybranej osobie z badanej grupy udaje się rozwiązać problem. Czy raczej mężczyzna czy kobieta?

$$P(M|S) = \frac{P(S|M)P(M)}{P(S)} = \frac{0.6 \times 0.6}{P(S)} = \frac{0.36}{P(S)}$$

Twierdzenie Bayesa. Przykład




Założmy, że losowo wybranej osobie z badanej grupy udaje się rozwiązać problem. Czy raczej mężczyzna czy kobieta?

$$P(M|S) = \frac{P(S|M)P(M)}{P(S)} = \frac{0.6 \times 0.6}{P(S)} = \frac{0.36}{P(S)}$$

$$P(K|S) =$$

Twierdzenie Bayesa. Przykład




Założmy, że losowo wybranej osobie z badanej grupy udaje się rozwiązać problem. Czy raczej mężczyzna czy kobieta?

$$P(M|S) = \frac{P(S|M)P(M)}{P(S)} = \frac{0.6 \times 0.6}{P(S)} = \frac{0.36}{P(S)}$$

$$P(K|S) = \frac{P(S|K)P(K)}{P(S)} =$$

Twierdzenie Bayesa. Przykład




Założmy, że losowo wybranej osobie z badanej grupy udaje się rozwiązać problem. Czy raczej mężczyzna czy kobieta?

$$P(M|S) = \frac{P(S|M)P(M)}{P(S)} = \frac{0.6 \times 0.6}{P(S)} = \frac{0.36}{P(S)}$$

$$P(K|S) = \frac{P(S|K)P(K)}{P(S)} = \frac{0.7 \times 0.4}{P(S)} =$$

Twierdzenie Bayesa. Przykład



Założmy, że losowo wybranej osobie z badanej grupy udaje się rozwiązać problem. Czy raczej mężczyzna czy kobieta?

$$P(M|S) = \frac{P(S|M)P(M)}{P(S)} = \frac{0.6 \times 0.6}{P(S)} = \frac{0.36}{P(S)}$$

$$P(K|S) = \frac{P(S|K)P(K)}{P(S)} = \frac{0.7 \times 0.4}{P(S)} = \frac{0.28}{P(S)}$$

Założmy, że mamy tabelę 1000 owoców (3 rodzaje - pomarańcze, banany i inne) z ich właściwościami - długie (lub nie), słodkie (lub nie), żółte (lub nie).

Założmy, że mamy tabelę 1000 owoców (3 rodzaje - pomarańcze, banany i inne) z ich właściwościami - długie (lub nie), słodkie (lub nie), żółte (lub nie).

	Owoc (Y)	Długi (X_1)	Słodki (X_2)	Żółty (X_3)
1	Pomarańcza	0	1	0
2	Banan	1	0	1
3	Banan	1	1	1
4	inny	1	1	0
..	..	..	..	..

Zagregowane dane w tabeli.

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomarańcza	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

Zagregowane dane w tabeli.

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomarańcza	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

Naszym celem jest przewidzenie, czy owoc to banan, pomarańcza czy inny, gdy znane są 3 cechy (długa, słodka, żółta).

Zagregowane dane w tabeli.

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomarańcza	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

Naszym celem jest przewidzenie, czy owoc to banan, pomarańcza czy inny, gdy znane są 3 cechy (długa, słodka, żółta). Na przykład $(X_1, X_2, X_3) = (1, 0, 1)$.

Zagregowane dane w tabeli.

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomarańcza	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

Naszym celem jest przewidzenie, czy owoc to banan, pomarańcza czy inny, gdy znane są 3 cechy (długa, słodka, żółta). Na przykład $(X_1, X_2, X_3) = (1, 0, 1)$. W tym celu sprawdzamy, które z poniższych jest największe:

Zagregowane dane w tabeli.

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomarańcza	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

Naszym celem jest przewidzenie, czy owoc to banan, pomarańcza czy inny, gdy znane są 3 cechy (długa, słodka, żółta). Na przykład $(X_1, X_2, X_3) = (1, 0, 1)$. W tym celu sprawdzamy, które z poniższych jest największe:

$$P(Y = \text{Banan} | X_1 = 1, X_2 = 0, X_3 = 1) -$$

$$P(Y = \text{Pomarańcza} | X_1 = 1, X_2 = 0, X_3 = 1) -$$

$$P(Y = \text{Inny} | X_1 = 1, X_2 = 0, X_3 = 1)$$

Naiwny klasyfikator bayesowski

Ze wzoru na prawdopodobieństwo warunkowe $P(A|B) = \frac{P(A \cap B)}{P(B)}$

Naiwny klasyfikator bayesowski

Ze wzoru na prawdopodobieństwo warunkowe $P(A|B) = \frac{P(A \cap B)}{P(B)}$
or $P(A \cap B) = P(A|B)P(B)$

Naiwny klasyfikator bayesowski

Ze wzoru na prawdopodobieństwo warunkowe $P(A|B) = \frac{P(A \cap B)}{P(B)}$
or $P(A \cap B) = P(A|B)P(B)$

$$P(Y|X_1, X_2, X_3)$$

Naiwny klasyfikator bayesowski

Ze wzoru na prawdopodobieństwo warunkowe $P(A|B) = \frac{P(A \cap B)}{P(B)}$
or $P(A \cap B) = P(A|B)P(B)$

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1, X_2, X_3, Y)}{P(X_1, X_2, X_3)}$$

Naiwny klasyfikator bayesowski

Ze wzoru na prawdopodobieństwo warunkowe $P(A|B) = \frac{P(A \cap B)}{P(B)}$
or $P(A \cap B) = P(A|B)P(B)$

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1, X_2, X_3, Y)}{P(X_1, X_2, X_3)}$$

Policzmy **licznik ułamka**

Naiwny klasyfikator bayesowski

Ze wzoru na prawdopodobieństwo warunkowe $P(A|B) = \frac{P(A \cap B)}{P(B)}$
or $P(A \cap B) = P(A|B)P(B)$

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1, X_2, X_3, Y)}{P(X_1, X_2, X_3)}$$

Policzmy **licznik ułamka**

$$P(X_1, X_2, X_3, Y)$$

Naiwny klasyfikator bayesowski

Ze wzoru na prawdopodobieństwo warunkowe $P(A|B) = \frac{P(A \cap B)}{P(B)}$
or $P(A \cap B) = P(A|B)P(B)$

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1, X_2, X_3, Y)}{P(X_1, X_2, X_3)}$$

Policzmy **licznik ułamka**

$$P(X_1, X_2, X_3, Y) = P(X_1|X_2, X_3, Y)P(X_2, X_3, Y)$$
$$=$$

Naiwny klasyfikator bayesowski

Ze wzoru na prawdopodobieństwo warunkowe $P(A|B) = \frac{P(A \cap B)}{P(B)}$
or $P(A \cap B) = P(A|B)P(B)$

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1, X_2, X_3, Y)}{P(X_1, X_2, X_3)}$$

Policzmy **licznik ułamka**

$$\begin{aligned} P(X_1, X_2, X_3, Y) &= P(X_1|X_2, X_3, Y)P(X_2, X_3, Y) \\ &= P(X_1|X_2, X_3, Y)P(X_2|X_3, Y)P(X_3, Y) = \end{aligned}$$

Naiwny klasyfikator bayesowski

Ze wzoru na prawdopodobieństwo warunkowe $P(A|B) = \frac{P(A \cap B)}{P(B)}$
or $P(A \cap B) = P(A|B)P(B)$

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1, X_2, X_3, Y)}{P(X_1, X_2, X_3)}$$

Policzmy **licznik ułamka**

$$\begin{aligned} P(X_1, X_2, X_3, Y) &= P(X_1|X_2, X_3, Y)P(X_2, X_3, Y) \\ &= P(X_1|X_2, X_3, Y)P(X_2|X_3, Y)P(X_3, Y) = \\ &= P(X_1|X_2, X_3, Y)P(X_2|X_3, Y)P(X_3|Y)P(Y) \end{aligned}$$

Naiwny klasyfikator bayesowski

$$P(X_1, X_2, X_3, Y) = P(X_1|X_2, X_3, Y)P(X_2|X_3, Y)P(X_3|Y)P(Y)$$

Dlaczego klasyfikator Bayesa nazywa się **naiwny**?

Naiwny klasyfikator bayesowski

$$P(X_1, X_2, X_3, Y) = P(X_1|X_2, X_3, Y)P(X_2|X_3, Y)P(X_3|Y)P(Y)$$

Dlaczego klasyfikator Bayesa nazywa się **naiwny**? Wynika to z następującego założenia, które upraszcza obliczenia.

Naiwny klasyfikator bayesowski

$$P(X_1, X_2, X_3, Y) = P(X_1|X_2, X_3, Y)P(X_2|X_3, Y)P(X_3|Y)P(Y)$$

Dlaczego klasyfikator Bayesa nazywa się **naiwny**? Wynika to z następującego założenia, które upraszcza obliczenia.

Naiwność

Zmienne X_1, X_2, X_3 są niezależne.

Naiwny klasyfikator bayesowski

$$P(X_1, X_2, X_3, Y) = P(X_1|X_2, X_3, Y)P(X_2|X_3, Y)P(X_3|Y)P(Y)$$

Dlaczego klasyfikator Bayesa nazywa się **naiwny**? Wynika to z następującego założenia, które upraszcza obliczenia.

Naiwność

Zmienne X_1, X_2, X_3 są niezależne.

Założenie implikuje

$$P(X_1|X_2, X_3, Y) = P(X_1|Y)$$

Naiwny klasyfikator bayesowski

$$P(X_1, X_2, X_3, Y) = P(X_1|X_2, X_3, Y)P(X_2|X_3, Y)P(X_3|Y)P(Y)$$

Dlaczego klasyfikator Bayesa nazywa się **naiwny**? Wynika to z następującego założenia, które upraszcza obliczenia.

Naiwność

Zmienne X_1, X_2, X_3 są niezależne.

Założenie implikuje

$$P(X_1|X_2, X_3, Y) = P(X_1|Y) \text{ oraz } P(X_2|X_3, Y) = P(X_2|Y)$$

Naiwny klasyfikator bayesowski

$$P(X_1, X_2, X_3, Y) = P(X_1|X_2, X_3, Y)P(X_2|X_3, Y)P(X_3|Y)P(Y)$$

Dlaczego klasyfikator Bayesa nazywa się **naiwny**? Wynika to z następującego założenia, które upraszcza obliczenia.

Naiwność

Zmienne X_1, X_2, X_3 są niezależne.

Założenie implikuje

$$P(X_1|X_2, X_3, Y) = P(X_1|Y) \text{ oraz } P(X_2|X_3, Y) = P(X_2|Y)$$

a w konsekwencji

$$P(X_1, X_2, X_3, Y) = P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y).$$

Naiwny klasyfikator bayesowski

$$P(X_1, X_2, X_3, Y) = P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y).$$

Naiwny klasyfikator bayesowski (wzór)

Naiwny klasyfikator bayesowski

$$P(X_1, X_2, X_3, Y) = P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y).$$

Naiwny klasyfikator bayesowski (wzór)

$$P(Y|X_1, X_2, X_3) =$$

Naiwny klasyfikator bayesowski

$$P(X_1, X_2, X_3, Y) = P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y).$$

Naiwny klasyfikator bayesowski (wzór)

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1, X_2, X_3, Y)}{P(X_1, X_2, X_3)} =$$

Naiwny klasyfikator bayesowski

$$P(X_1, X_2, X_3, Y) = P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y).$$

Naiwny klasyfikator bayesowski (wzór)

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1, X_2, X_3, Y)}{P(X_1, X_2, X_3)} = \frac{P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y)}{P(X_1, X_2, X_3)}$$

Naiwny klasyfikator bayesowski

$$P(X_1, X_2, X_3, Y) = P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y).$$

Naiwny klasyfikator bayesowski (wzór)

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1, X_2, X_3, Y)}{P(X_1, X_2, X_3)} = \frac{P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y)}{P(X_1, X_2, X_3)}$$

Wracając do przykładu: która z liczb jest największa?

$$P(Y = \text{Banan}|X_1 = 1, X_2 = 0, X_3 = 1)$$

$$P(Y = \text{Pomarańcza}|X_1 = 1, X_2 = 0, X_3 = 1)$$

$$P(Y = \text{Inny}|X_1 = 1, X_2 = 0, X_3 = 1)$$

Naiwny klasyfikator bayesowski

Naiwny klasyfikator bayesowski (wzór)

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y)}{P(X_1, X_2, X_3)}$$

Chcemy znaleźć Y (w zbiorze {banan, pomarańcza, inne}), które maksymalizują **licznik** formuły naiwnego klasyfikatora Bayesa: $P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y)$.

Naiwny klasyfikator bayesowski

Naiwny klasyfikator bayesowski (wzór)

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y)}{P(X_1, X_2, X_3)}$$

Chcemy znaleźć Y (w zbiorze {banan, pomarańcza, inne}), które maksymalizują **licznik** formuły naiwnego klasyfikatora Bayesa: $P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y)$. W naszym przykładzie znajdujemy największą liczbę spośród:

Naiwny klasyfikator bayesowski

Naiwny klasyfikator bayesowski (wzór)

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y)}{P(X_1, X_2, X_3)}$$

Chcemy znaleźć Y (w zbiorze {banan, pomarańcza, inne}), które maksymalizują **licznik** formuły naiwnego klasyfikatora Bayesa: $P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y)$. W naszym przykładzie znajdujemy największą liczbę spośród:
 $P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan})$

Naiwny klasyfikator bayesowski

Naiwny klasyfikator bayesowski (wzór)

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y)}{P(X_1, X_2, X_3)}$$

Chcemy znaleźć Y (w zbiorze {banan, pomarańcza, inne}), które maksymalizują **licznik** formuły naiwnego klasyfikatora Bayesa: $P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y)$. W naszym przykładzie znajdujemy największą liczbę spośród:

$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan})$
 $P(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom})$

Naiwny klasyfikator bayesowski

Naiwny klasyfikator bayesowski (wzór)

$$P(Y|X_1, X_2, X_3) = \frac{P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y)}{P(X_1, X_2, X_3)}$$

Chcemy znaleźć Y (w zbiorze {banan, pomarańcza, inne}), które maksymalizują **licznik** formuły naiwnego klasyfikatora Bayesa: $P(X_1|Y)P(X_2|Y)P(X_3|Y)P(Y)$. W naszym przykładzie znajdujemy największą liczbę spośród:

$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan})$

$P(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom})$

$P(\text{długi}|\text{inny})P(\text{nie słodki}|\text{inny})P(\text{żółty}|\text{inny})P(\text{inny})$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan})$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) = \frac{400}{500}$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) = \frac{400}{500} \times \frac{150}{500}$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) = \\ \frac{400}{500} \times \frac{150}{500} \times \frac{450}{500}$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) = \\ \frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000}$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) = \frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) = \frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$
$$PP(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom})$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) =$$

$$\frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$

$$PP(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom}) =$$

$$\frac{0}{300}$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) =$$

$$\frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$

$$PP(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom}) =$$

$$\frac{0}{300} \times \frac{150}{300}$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) =$$

$$\frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$

$$PP(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom}) =$$

$$\frac{0}{300} \times \frac{150}{300} \times \frac{300}{300}$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) =$$

$$\frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$

$$PP(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom}) =$$

$$\frac{0}{300} \times \frac{150}{300} \times \frac{300}{300} \times \frac{300}{1000}$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) =$$

$$\frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$

$$PP(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom}) =$$

$$\frac{0}{300} \times \frac{150}{300} \times \frac{300}{300} \times \frac{300}{1000} = 0$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) =$$

$$\frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$

$$PP(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom}) =$$

$$\frac{0}{300} \times \frac{150}{300} \times \frac{300}{300} \times \frac{300}{1000} = 0$$

$$P(\text{długi}|\text{inny})P(\text{nie słodki}|\text{inny})P(\text{żółty}|\text{inny})P(\text{inny})$$

Naiwny klasyfikator bayesowski

Y	X ₁ = 1	X ₁ = 0	X ₂ = 1	X ₂ = 0	X ₃ = 1	X ₃ = 0	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) =$$

$$\frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$

$$PP(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom}) =$$

$$\frac{0}{300} \times \frac{150}{300} \times \frac{300}{300} \times \frac{300}{1000} = 0$$

$$P(\text{długi}|\text{inny})P(\text{nie słodki}|\text{inny})P(\text{żółty}|\text{inny})P(\text{inny}) =$$

$$\frac{100}{200}$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) =$$

$$\frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$

$$P(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom}) =$$

$$\frac{0}{300} \times \frac{150}{300} \times \frac{300}{300} \times \frac{300}{1000} = 0$$

$$P(\text{długi}|\text{inny})P(\text{nie słodki}|\text{inny})P(\text{żółty}|\text{inny})P(\text{inny}) =$$

$$\frac{100}{200} \times \frac{50}{200}$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) =$$

$$\frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$

$$P(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom}) =$$

$$\frac{0}{300} \times \frac{150}{300} \times \frac{300}{300} \times \frac{300}{1000} = 0$$

$$P(\text{długi}|\text{inny})P(\text{nie słodki}|\text{inny})P(\text{żółty}|\text{inny})P(\text{inny}) =$$

$$\frac{100}{200} \times \frac{50}{200} \times \frac{50}{200}$$

Naiwny klasyfikator bayesowski

Y	X ₁ = 1	X ₁ = 0	X ₂ = 1	X ₂ = 0	X ₃ = 1	X ₃ = 0	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) =$$

$$\frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$

$$P(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom}) =$$

$$\frac{0}{300} \times \frac{150}{300} \times \frac{300}{300} \times \frac{300}{1000} = 0$$

$$P(\text{długi}|\text{inny})P(\text{nie słodki}|\text{inny})P(\text{żółty}|\text{inny})P(\text{inny}) =$$

$$\frac{100}{200} \times \frac{50}{200} \times \frac{50}{200} \times \frac{200}{1000}$$

Naiwny klasyfikator bayesowski

Y	$X_1 = 1$	$X_1 = 0$	$X_2 = 1$	$X_2 = 0$	$X_3 = 1$	$X_3 = 0$	
Owoc	długi	nie długi	słodki	nie słodki	żółty	nie żółty	w sumie
banan	400	100	350	150	450	50	500
pomar	0	300	150	150	300	0	300
inny	100	100	150	50	50	150	200
w sumie	500	500	650	350	800	200	1000

$$P(\text{długi}|\text{banan})P(\text{nie słodki}|\text{banan})P(\text{żółty}|\text{banan})P(\text{banan}) =$$

$$\frac{400}{500} \times \frac{150}{500} \times \frac{450}{500} \times \frac{500}{1000} = 0.108$$

$$P(\text{długi}|\text{pom})P(\text{nie słodki}|\text{pom})P(\text{żółty}|\text{pom})P(\text{pom}) =$$

$$\frac{0}{300} \times \frac{150}{300} \times \frac{300}{300} \times \frac{300}{1000} = 0$$

$$P(\text{długi}|\text{inny})P(\text{nie słodki}|\text{inny})P(\text{żółty}|\text{inny})P(\text{inny}) =$$

$$\frac{100}{200} \times \frac{50}{200} \times \frac{50}{200} \times \frac{200}{1000} = 0.0062$$

Naiwny klasyfikator bayesowski

Model

$$P(Y = c_k \mid X_1, \dots, X_n) \propto P(Y = c_k) \prod_{i=1}^n P(X_i \mid Y = c_k)$$

Naiwny klasyfikator bayesowski

Model

$$P(Y = c_k \mid X_1, \dots, X_n) \propto P(Y = c_k) \prod_{i=1}^n P(X_i \mid Y = c_k)$$

symbol $\propto$ oznacza proporcjonalny lub inaczej z dokładnością do stałej (mianownik)

Naiwny klasyfikator bayesowski

Model

$$P(Y = c_k \mid X_1, \dots, X_n) \propto P(Y = c_k) \prod_{i=1}^n P(X_i \mid Y = c_k)$$


symbol $\propto$ oznacza proporcjonalny lub inaczej z dokładnością do stałej (mianownik)

Klasyfikator

$$\hat{Y} = \operatorname{argmax}_{k \in \{1, \dots, K\}} P(Y = c_k) \prod_{i=1}^n P(X_i \mid Y = c_k)$$

Problem: Dział HR otrzymuje co miesiąc ponad 500 CV. Czy powinni stosować metody klasyfikacji, aby wybrać najlepszych kandydatów i zaoszczędzić czas/pieniądze?

Problem: Dział HR otrzymuje co miesiąc ponad 500 CV. Czy powinni stosować metody klasyfikacji, aby wybrać najlepszych kandydatów i zaoszczędzić czas/pieniądze?



Pima Indians Diabetes Database

Celem zbioru danych jest przewidywanie, czy pacjentka ma cukrzycę, w oparciu o określone pomiary diagnostyczne.

Gaussowski naiwny Bayes

Zależna zmienna kategoryalna Y ma m kategorii $c_1, \dots, c_m$.

Gaussowski naiwny Bayes

Zależna zmienna kategoryalna Y ma m kategorii $c_1, \dots, c_m$.
Zależy ona od n ciągłych zmiennych $X_1, \dots, X_n$.

Gaussowski naiwny Bayes

Zależna zmienna kategoryalna Y ma m kategorii $c_1, \dots, c_m$.
Zależy ona od n ciągłych zmiennych $X_1, \dots, X_n$. Zakładamy ,
że zmienna $X_i|Y = c_k$ ma rozkład normalny.

Gaussowski naiwny Bayes

Zależna zmienna kategoryjalna Y ma m kategorii $c_1, \dots, c_m$.
Zależy ona od n ciągłych zmiennych $X_1, \dots, X_n$. Zakładamy ,
że zmienna $X_i|Y = c_k$ ma rozkład normalny. Gęstość
estymujemy następująco

$$f_i(v|Y = c_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(v - \mu_k)^2}{2\sigma_k^2}\right),$$

Gaussowski naiwny Bayes

Zależna zmienna kategoryjalna Y ma m kategorii $c_1, \dots, c_m$.
Zależy ona od n ciągłych zmiennych $X_1, \dots, X_n$. Zakładamy ,
że zmienna $X_i|Y = c_k$ ma rozkład normalny. Gęstość
estymujemy następująco

$$f_i(v|Y = c_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(v - \mu_k)^2}{2\sigma_k^2}\right),$$

gdzie μ_k to średnia z próby dla X_i przy $y = c_k$,

Gaussowski naiwny Bayes

Zależna zmienna kategoryjalna Y ma m kategorii $c_1, \dots, c_m$.
Zależy ona od n ciągłych zmiennych $X_1, \dots, X_n$. Zakładamy ,
że zmienna $X_i|Y = c_k$ ma rozkład normalny. Gęstość
estymujemy następująco

$$f_i(v|Y = c_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(v - \mu_k)^2}{2\sigma_k^2}\right),$$

gdzie μ_k to średnia z próby dla X_i przy $y = c_k$,
a σ_k^2 to wariancja z próby dla X_i przy $y = c_k$.

Gaussowski naiwny Bayes

Zależna zmienna kategoryjalna Y ma m kategorii $c_1, \dots, c_m$.
Zależy ona od n ciągłych zmiennych $X_1, \dots, X_n$. Zakładamy ,
że zmienna $X_i|Y = c_k$ ma rozkład normalny. Gęstość
estymujemy następująco

$$f_i(v|Y = c_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(v - \mu_k)^2}{2\sigma_k^2}\right),$$

gdzie μ_k to średnia z próby dla X_i przy $y = c_k$,
a σ_k^2 to wariancja z próby dla X_i przy $y = c_k$.

Dla próby $X_1 = v_1, \dots, X_n = v_n$ maksymalizujemy wyrażenie:

Gaussowski naiwny Bayes

Zależna zmienna kategoryjalna Y ma m kategorii $c_1, \dots, c_m$.
Zależy ona od n ciągłych zmiennych $X_1, \dots, X_n$. Zakładamy, że zmienna $X_i|Y = c_k$ ma rozkład normalny. Gęstość estymujemy następująco

$$f_i(v|Y = c_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(v - \mu_k)^2}{2\sigma_k^2}\right),$$

gdzie μ_k to średnia z próby dla X_i przy $y = c_k$,
a σ_k^2 to wariancja z próby dla X_i przy $y = c_k$.

Dla próby $X_1 = v_1, \dots, X_n = v_n$ maksymalizujemy wyrażenie:

$$\hat{Y} = \operatorname{argmax}_{k \in \{1, \dots, m\}} P(Y = c_k) \prod_{i=1}^n f_i(v_i | Y = c_k) =$$

Gaussowski naiwny Bayes

Zależna zmienna kategoryjalna Y ma m kategorii $c_1, \dots, c_m$.
Zależy ona od n ciągłych zmiennych $X_1, \dots, X_n$. Zakładamy, że zmienna $X_i|Y = c_k$ ma rozkład normalny. Gęstość estymujemy następująco

$$f_i(v|Y = c_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(v - \mu_k)^2}{2\sigma_k^2}\right),$$

gdzie μ_k to średnia z próby dla X_i przy $y = c_k$,
a σ_k^2 to wariancja z próby dla X_i przy $y = c_k$.

Dla próby $X_1 = v_1, \dots, X_n = v_n$ maksymalizujemy wyrażenie:

$$\hat{Y} = \underset{k \in \{1, \dots, m\}}{\operatorname{argmax}} P(Y = c_k) \prod_{i=1}^n f_i(v_i | Y = c_k) =$$
$$\underset{k \in \{1, \dots, m\}}{\operatorname{argmax}} \log P(Y = c_k) + \sum_{i=1}^n \log(f_i(v_i | Y = c_k))$$

Wykrywanie spamu w oparciu o naiwny klasyfikator bayesowski

S - spam, $\neg S$ - nie spam

Wykrywanie spamu w oparciu o naiwny klasyfikator bayesowski

S - spam, $\neg S$ - nie spam

B - zawiera słowo 'bitcoin'

Wykrywanie spamu w oparciu o naiwny klasyfikator bayesowski

S - spam, $\neg S$ - nie spam

B - zawiera słowo 'bitcoin'

Założenie: $P(S) = P(\neg S) = 0.5$ - spam i zwykłe maile są równie częste.

Wykrywanie spamu w oparciu o naiwny klasyfikator bayesowski

S - spam, $\neg S$ - nie spam

B - zawiera słowo 'bitcoin'

Założenie: $P(S) = P(\neg S) = 0.5$ - spam i zwykłe maile są równie częste. **Z tw. o prawdopodobieństwie całkowitym**

Wykrywanie spamu w oparciu o naiwny klasyfikator bayesowski

S - spam, $\neg S$ - nie spam

B - zawiera słowo 'bitcoin'

Założenie: $P(S) = P(\neg S) = 0.5$ - spam i zwykłe maile są równie częste. **Z tw. o prawdopodobieństwie całkowitym**

$$P(S|B) =$$

Wykrywanie spamu w oparciu o naiwny klasyfikator bayesowski

S - spam, $\neg S$ - nie spam

B - zawiera słowo 'bitcoin'

Założenie: $P(S) = P(\neg S) = 0.5$ - spam i zwykłe maile są równie częste. **Z tw. o prawdopodobieństwie całkowitym**

$$P(S|B) = \frac{P(B|S)P(S)}{P(B)} =$$

Wykrywanie spamu w oparciu o naiwny klasyfikator bayesowski

S - spam, $\neg S$ - nie spam

B - zawiera słowo 'bitcoin'

Założenie: $P(S) = P(\neg S) = 0.5$ - spam i zwykłe maile są równie częste. **Z tw. o prawdopodobieństwie całkowitym**

$$P(S|B) = \frac{P(B|S)P(S)}{P(B)} = \frac{P(B|S)P(S)}{P(B|S)P(S) + P(B|\neg S)P(\neg S)}$$

Wykrywanie spamu w oparciu o naiwny klasyfikator bayesowski

S - spam, $\neg S$ - nie spam

B - zawiera słowo 'bitcoin'

Założenie: $P(S) = P(\neg S) = 0.5$ - spam i zwykłe maile są równie częste. **Z tw. o prawdopodobieństwie całkowitym**

$$P(S|B) = \frac{P(B|S)P(S)}{P(B)} = \frac{P(B|S)P(S)}{P(B|S)P(S) + P(B|\neg S)P(\neg S)}$$

$$P(S|B) = \frac{P(B|S)}{P(B|S) + P(B|\neg S)}$$

Wykrywanie spamu w oparciu o naiwny klasyfikator bayesowski

S - spam, $\neg S$ - nie spam

B - zawiera słowo 'bitcoin'

Założenie: $P(S) = P(\neg S) = 0.5$ - spam i zwykłe maile są równie częste. **Z tw. o prawdopodobieństwie całkowitym**

$$P(S|B) = \frac{P(B|S)P(S)}{P(B)} = \frac{P(B|S)P(S)}{P(B|S)P(S) + P(B|\neg S)P(\neg S)}$$

$$P(S|B) = \frac{P(B|S)}{P(B|S) + P(B|\neg S)}$$

Jeśli $P(B|S) = 0.5$ i $P(B|\neg S) = 0.01$.

Wykrywanie spamu w oparciu o naiwny klasyfikator bayesowski

S - spam, $\neg S$ - nie spam

B - zawiera słowo 'bitcoin'

Założenie: $P(S) = P(\neg S) = 0.5$ - spam i zwykłe maile są równie częste. **Z tw. o prawdopodobieństwie całkowitym**

$$P(S|B) = \frac{P(B|S)P(S)}{P(B)} = \frac{P(B|S)P(S)}{P(B|S)P(S) + P(B|\neg S)P(\neg S)}$$

$$P(S|B) = \frac{P(B|S)}{P(B|S) + P(B|\neg S)}$$

Jeśli $P(B|S) = 0.5$ i $P(B|\neg S) = 0.01$. To

$$P(S|B) = \frac{0.5}{0.5 + 0.01} = 98\%$$

Wykrywanie spamu w oparciu o naiwny klasyfikator bayesowski

S - spam, $\neg S$ - nie spam

B - zawiera słowo 'bitcoin'

Założenie: $P(S) = P(\neg S) = 0.5$ - spam i zwykłe maile są równie częste. **Z tw. o prawdopodobieństwie całkowitym**

$$P(S|B) = \frac{P(B|S)P(S)}{P(B)} = \frac{P(B|S)P(S)}{P(B|S)P(S) + P(B|\neg S)P(\neg S)}$$

$$P(S|B) = \frac{P(B|S)}{P(B|S) + P(B|\neg S)}$$

Jeśli $P(B|S) = 0.5$ i $P(B|\neg S) = 0.01$. To

$$P(S|B) = \frac{0.5}{0.5 + 0.01} = 98\% \quad \text{oraz} \quad P(\neg S|B) = \frac{0.01}{0.5 + 0.01} = 2\%$$

Niech $D = \{w_1, w_2, \dots, w_n\}$ będzie słownikiem.

Detektor spamu

Niech $D = \{w_1, w_2, \dots, w_n\}$ będzie słownikiem.

$D = \{\text{'bitcoin'}, \text{'Rolex'}, \text{'sex'}, \text{'dear'}, \text{'regards'}, \text{'attach'}, \dots\}$

Detektor spamu

Niech $D = \{w_1, w_2, \dots, w_n\}$ będzie słownikiem.

$D = \{'bitcoin', 'Rolex', 'sex', 'dear', 'regards', 'attach', \dots\}$

$X_i = 1$ jeśli mail zawiera w_i , w przeciwnym razie $X_i = 0$.

Detektor spamu

Niech $D = \{w_1, w_2, \dots, w_n\}$ będzie słownikiem.

$D = \{'bitcoin', 'Rolex', 'sex', 'dear', 'regards', 'attach', \dots\}$

$X_i = 1$ jeśli mail zawiera w_i , w przeciwnym razie $X_i = 0$. Niech $x_i = 0, 1$. Założenie naiwności

Detektor spamu

Niech $D = \{w_1, w_2, \dots, w_n\}$ będzie słownikiem.

$D = \{'bitcoin', 'Rolex', 'sex', 'dear', 'regards', 'attach', \dots\}$

$X_i = 1$ jeśli mail zawiera w_i , w przeciwnym razie $X_i = 0$. Niech $x_i = 0, 1$. Założenie naiwności

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) =$$

$$P(X_1 = x_1)P(X_2 = x_2) \dots P(X_n = x_n)$$

Detektor spamu

Niech $D = \{w_1, w_2, \dots, w_n\}$ będzie słownikiem.

$D = \{'bitcoin', 'Rolex', 'sex', 'dear', 'regards', 'attach', \dots\}$

$X_i = 1$ jeśli mail zawiera w_i , w przeciwnym razie $X_i = 0$. Niech $x_i = 0, 1$. Założenie naiwności

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) =$$

$$P(X_1 = x_1)P(X_2 = x_2) \dots P(X_n = x_n) = \prod_{i=1}^n P(X_i = x_i)$$

Detektor spamu

Niech $D = \{w_1, w_2, \dots, w_n\}$ będzie słownikiem.

$D = \{'bitcoin', 'Rolex', 'sex', 'dear', 'regards', 'attach', \dots\}$

$X_i = 1$ jeśli mail zawiera w_i , w przeciwnym razie $X_i = 0$. Niech $x_i = 0, 1$. Założenie naiwności

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) =$$

$$P(X_1 = x_1)P(X_2 = x_2) \dots P(X_n = x_n) = \prod_{i=1}^n P(X_i = x_i)$$

$$P(S|X_1 = x_1, \dots, X_n = x_n) = \frac{\prod_{i=1}^n P(X_i = x_i|S)}{\prod_{i=1}^n P(X_i = x_i|S) + \prod_{i=1}^n P(X_i = x_i|\neg S)}$$

Detektor spamu

Niech $D = \{w_1, w_2, \dots, w_n\}$ będzie słownikiem.

$D = \{\text{'bitcoin'}, \text{'Rolex'}, \text{'sex'}, \text{'dear'}, \text{'regards'}, \text{'attach'}, \dots\}$

$X_i = 1$ jeśli mail zawiera w_i , w przeciwnym razie $X_i = 0$. Niech $x_i = 0, 1$. Założenie naiwności

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) =$$

$$P(X_1 = x_1)P(X_2 = x_2) \dots P(X_n = x_n) = \prod_{i=1}^n P(X_i = x_i)$$

$$P(S|X_1 = x_1, \dots, X_n = x_n) = \frac{\prod_{i=1}^n P(X_i = x_i|S)}{\prod_{i=1}^n P(X_i = x_i|S) + \prod_{i=1}^n P(X_i = x_i|\neg S)}$$

$$P(\neg S|X_1 = x_1, \dots, X_n = x_n) = \frac{\prod_{i=1}^n P(X_i = x_i|\neg S)}{\prod_{i=1}^n P(X_i = x_i|S) + \prod_{i=1}^n P(X_i = x_i|\neg S)}$$

Detektor spamu

Jeśli $\prod_{i=1}^n P(X_i = x_i|S) > \prod_{i=1}^n P(X_i = x_i|\neg S)$, to mail klasyfikujemy jako spam.

Detektor spamu

Jeśli $\prod_{i=1}^n P(X_i = x_i|S) > \prod_{i=1}^n P(X_i = x_i|\neg S)$, to mail
klasyfikujemy jako spam. Ponieważ $\log(\prod_{i=1}^n a_i) = \sum_{i=1}^n \log(a_i)$

Detektor spamu

Jeśli $\prod_{i=1}^n P(X_i = x_i|S) > \prod_{i=1}^n P(X_i = x_i|\neg S)$, to mail klasyfikujemy jako spam. Ponieważ $\log(\prod_{i=1}^n a_i) = \sum_{i=1}^n \log(a_i)$ i $x \mapsto \log x$ jest rosnąca,

Detektor spamu

Jeśli $\prod_{i=1}^n P(X_i = x_i|S) > \prod_{i=1}^n P(X_i = x_i|\neg S)$, to mail klasyfikujemy jako spam. Ponieważ $\log(\prod_{i=1}^n a_i) = \sum_{i=1}^n \log(a_i)$ i $x \mapsto \log x$ jest rosnąca, to, równoważnie, jeśli

$$\sum_{i=1}^n \log(P(X_i = x_i|S)) > \sum_{i=1}^n \log(P(X_i = x_i|\neg S)),$$

to mail klasyfikujemy jako spam.

Detektor spamu

Jeśli $\prod_{i=1}^n P(X_i = x_i|S) > \prod_{i=1}^n P(X_i = x_i|\neg S)$, to mail klasyfikujemy jako spam. Ponieważ $\log(\prod_{i=1}^n a_i) = \sum_{i=1}^n \log(a_i)$ i $x \mapsto \log x$ jest rosnąca, to, równoważnie, jeśli

$$\sum_{i=1}^n \log(P(X_i = x_i|S)) > \sum_{i=1}^n \log(P(X_i = x_i|\neg S)),$$

to mail klasyfikujemy jako spam. Dlaczego logarytmy zamiast iloczynów?

Detektor spamu

Jeśli $\prod_{i=1}^n P(X_i = x_i|S) > \prod_{i=1}^n P(X_i = x_i|\neg S)$, to mail klasyfikujemy jako spam. Ponieważ $\log(\prod_{i=1}^n a_i) = \sum_{i=1}^n \log(a_i)$ i $x \mapsto \log x$ jest rosnąca, to, równoważnie, jeśli

$$\sum_{i=1}^n \log(P(X_i = x_i|S)) > \sum_{i=1}^n \log(P(X_i = x_i|\neg S)),$$

to mail klasyfikujemy jako spam. Dlaczego logarytmy zamiast iloczynów?

$$\frac{1}{100} \times \frac{1}{1000} \times \frac{1}{10} = \frac{1}{1000000} = \frac{1}{10^6}$$

Detektor spamu

Jeśli $\prod_{i=1}^n P(X_i = x_i|S) > \prod_{i=1}^n P(X_i = x_i|\neg S)$, to mail klasyfikujemy jako spam. Ponieważ $\log(\prod_{i=1}^n a_i) = \sum_{i=1}^n \log(a_i)$ i $x \mapsto \log x$ jest rosnąca, to, równoważnie, jeśli

$$\sum_{i=1}^n \log(P(X_i = x_i|S)) > \sum_{i=1}^n \log(P(X_i = x_i|\neg S)),$$

to mail klasyfikujemy jako spam. Dlaczego logarytmy zamiast iloczynów?

$$\frac{1}{100} \times \frac{1}{1000} \times \frac{1}{10} = \frac{1}{1000000} = \frac{1}{10^6}$$

$$\log\left(\frac{1}{100} \times \frac{1}{1000} \times \frac{1}{10}\right) =$$

Detektor spamu

Jeśli $\prod_{i=1}^n P(X_i = x_i|S) > \prod_{i=1}^n P(X_i = x_i|\neg S)$, to mail klasyfikujemy jako spam. Ponieważ $\log(\prod_{i=1}^n a_i) = \sum_{i=1}^n \log(a_i)$ i $x \mapsto \log x$ jest rosnąca, to, równoważnie, jeśli

$$\sum_{i=1}^n \log(P(X_i = x_i|S)) > \sum_{i=1}^n \log(P(X_i = x_i|\neg S)),$$

to mail klasyfikujemy jako spam. Dlaczego logarytmy zamiast iloczynów?

$$\frac{1}{100} \times \frac{1}{1000} \times \frac{1}{10} = \frac{1}{1000000} = \frac{1}{10^6}$$

$$\log\left(\frac{1}{100} \times \frac{1}{1000} \times \frac{1}{10}\right) = \log \frac{1}{100} + \log \frac{1}{1000} + \log \frac{1}{10} =$$

Detektor spamu

Jeśli $\prod_{i=1}^n P(X_i = x_i|S) > \prod_{i=1}^n P(X_i = x_i|\neg S)$, to mail klasyfikujemy jako spam. Ponieważ $\log(\prod_{i=1}^n a_i) = \sum_{i=1}^n \log(a_i)$ i $x \mapsto \log x$ jest rosnąca, to, równoważnie, jeśli

$$\sum_{i=1}^n \log(P(X_i = x_i|S)) > \sum_{i=1}^n \log(P(X_i = x_i|\neg S)),$$

to mail klasyfikujemy jako spam. Dlaczego logarytmy zamiast iloczynów?

$$\frac{1}{100} \times \frac{1}{1000} \times \frac{1}{10} = \frac{1}{1000000} = \frac{1}{10^6}$$

$$\begin{aligned} \log\left(\frac{1}{100} \times \frac{1}{1000} \times \frac{1}{10}\right) &= \log \frac{1}{100} + \log \frac{1}{1000} + \log \frac{1}{10} = \\ &= -2 + (-3) + (-1) = -6 \end{aligned}$$

Trenowanie detektora spamu

Używając bazy zawierającej spam i nie-spam tworzymy słownik:

Trenowanie detektora spamu

Używając bazy zawierającej spam i nie-spam tworzymy słownik:

$$D = \{ \text{'bitcoin'}, \text{'Rolex'}, \text{'sex'}, \text{'dear'}, \text{'regards'}, \text{'attach'}, \dots \}$$

Trenowanie detektora spamu

Używając bazy zawierającej spam i nie-spam tworzymy słownik:

$$D = \{ \text{'bitcoin'}, \text{'Rolex'}, \text{'sex'}, \text{'dear'}, \text{'regards'}, \text{'attach'}, \dots \}$$

i liczymy prawdopodobieństwa

Trenowanie detektora spamu

Używając bazy zawierającej spam i nie-spam tworzymy słownik:

$D = \{ \text{'bitcoin', 'Rolex', 'sex', 'dear', 'regards', 'attach', ...} \}$

i liczymy prawdopodobieństwa

$$P(X_i = 1|S) = \frac{\text{liczba spamu zawierającego } w_i}{\text{liczba całego spamu}}$$

Trenowanie detektora spamu

Używając bazy zawierającej spam i nie-spam tworzymy słownik:

$D = \{ \text{'bitcoin', 'Rolex', 'sex', 'dear', 'regards', 'attach', ...} \}$

i liczymy prawdopodobieństwa

$$P(X_i = 1|S) = \frac{\text{liczba spamu zawierającego } w_i}{\text{liczba całego spamu}}$$

$$P(X_i = 0|S) = 1 - P(X_i = 1|S)$$

Trenowanie detektora spamu

Używając bazy zawierającej spam i nie-spam tworzymy słownik:

$D = \{ \text{'bitcoin'}, \text{'Rolex'}, \text{'sex'}, \text{'dear'}, \text{'regards'}, \text{'attach'}, \dots \}$

i liczymy prawdopodobieństwa

$$P(X_i = 1|S) = \frac{\text{liczba spamu zawierającego } w_i}{\text{liczba całego spamu}}$$

$$P(X_i = 0|S) = 1 - P(X_i = 1|S)$$

$$P(X_i = 1|\neg S) = \frac{\text{liczba nie-spamu zawierająca } w_i}{\text{liczba nie-spamu}}$$

Trenowanie detektora spamu

Używając bazy zawierającej spam i nie-spam tworzymy słownik:

$D = \{ \text{'bitcoin', 'Rolex', 'sex', 'dear', 'regards', 'attach', ...} \}$

i liczymy prawdopodobieństwa

$$P(X_i = 1|S) = \frac{\text{liczba spamu zawierającego } w_i}{\text{liczba całego spamu}}$$

$$P(X_i = 0|S) = 1 - P(X_i = 1|S)$$

$$P(X_i = 1|\neg S) = \frac{\text{liczba nie-spamu zawierająca } w_i}{\text{liczba nie-spamu}}$$

$$P(X_i = 0|\neg S) = 1 - P(X_i = 1|\neg S)$$