

Zadanie 1: Klasyfikacja symptomów depresji na podstawie tekstu (Naiwny Bayes)

Opis zadania

Celem zadania jest zbudowanie modelu klasyfikacyjnego, który przewiduje, czy autorka/autor wpisu ma **symptomy zaburzeń depresyjnych (1)**, czy **nie (0)**. Do klasyfikacji zostanie użyty algorytm **naiwnego Bayesa**, operujący na danych tekstowych. Model zostanie wytrenowany na zbiorze **danych depresja.csv**, a następnie użyty do predykcji dla wpisów ze zbioru **depresja_test.csv**.

Opis zbioru danych

Zbiór **depresja.csv** zawiera **7231 rekordy** a **depresja_test.csv** **500 rekordów**.

Nazwa zmiennej	Opis
clean_text	Tekst po wstępnym oczyszczeniu
is_depression	Symptomy zaburzeń depresyjnych: 1 (tak), 0 (nie) (zmienna docelowa)

Kryteria oceny

Model będzie oceniany na podstawie **accuracy score**.

Zakres pracy

Przygotowanie danych:

- Załaduj zbiór danych depresja.csv (dane treningowe) i depresja_test.csv (dane do predykcji).
- Sprawdź czy istnieją brakujące wartości w pliku depresja.csv. Jeśli istnieją, usuń je.
- Przekształć dane tekstowe (clean_text) na format numeryczny, który może być użyty przez algorytm naiwnego Bayesa (np. za pomocą **CountVectorizer** lub **TfidfVectorizer**).
- Podziel zbiór treningowy na cechy (X, czyli przetworzone dane tekstowe) i zmienną docelową (y, czyli is_depression).

Klasyfikacja metodą naiwnego Bayesa:

- Zbuduj model klasyfikatora **naiwnego Bayesa** (np. MultinomialNB dla danych tekstowych, lub GaussianNB jeśli zdecydujesz się na inne przetwarzanie cech).

- Wytrenuj model na przygotowanym zbiorze treningowym.
- Wykonaj predykcję klasy (0 lub 1) dla wpisów ze zbioru depresja_test.csv.

Prezentacja wyników:

- Utwórz plik d.csv zawierający wyłącznie kolumnę z przewidzianymi wartościami is_depression (0 lub 1) dla danych ze zbioru depresja_test.csv. Nazwą kolumny powinna być is_depression.

Rozwiązanie należy przestać w pliku jupyter notebook oraz pliku d.csv.

Zadanie 2: Klasyfikacja bankructw firm (Gausowski Naiwny Bayes)

Opis zadania

Celem zadania jest zbudowanie modelu klasyfikacyjnego, który na podstawie danych finansowych przedsiębiorstwa przewiduje, czy **firma zbankrutowała (b'1')**, czy **nie (b'0')**. Do klasyfikacji zostanie użyty algorytm **Gausowskiego naiwnego Bayesa**. Model zostanie wytrenowany na zbiorze danych bankructwa.csv, a następnie użyty do predykcji dla firm ze zbioru bankructwa_test.csv.

Opis zbioru danych

Zbiór **bankructwa.csv** zawiera **8792** rekordy a **bankructwa_test.csv 1000 rekordów**.

Zmienne X1-X64 to różne wskaźniki finansowe wyliczone na podstawie sprawozdań finansowych, takie jak:

- **X1**: zysk netto / aktywa ogółem
- **X2**: zobowiązania ogółem / aktywa ogółem
- **X3**: kapitał obrotowy / aktywa ogółem
- **X4-X64**: różne parametry finansowe
- **class**: status firmy: b'0' (brak bankructwa), b'1' (bankructwo) (**zmienna docelowa**, tylko w bankructwa.csv)

Kryteria oceny

Głównym kryterium oceny jest **czułość (recall) na poziomie 0.95 dla klasy b'1' (bankructwo)**. Oznacza to, że model powinien poprawnie identyfikować co najmniej 95% firm, które faktycznie zbankrutowały, aby zabezpieczyć inwestora przed stratami. Dodatkowo, należy dopasować odpowiedni **próg odcięcia prawdopodobieństwa bankructwa**, aby osiągnąć ten cel.

Zakres pracy

Przygotowanie danych:

- Załaduj zbiór danych bankructwa.csv (dane treningowe) i bankructwa_test.csv (dane do predykcji).
- **Obsłuż brakujące wartości** w kolumnach X1-X64, jeśli istnieją. Metoda naiwnego Bayesa jest wrażliwa na braki. Możesz zastosować np. imputację (średnią, medianę) lub usunięcie wierszy/kolumn, w zależności od skali problemu i rozkładu danych.
- Sprawdź typ zmiennej class i ewentualnie przekonwertuj ją na numeryczny (0 i 1).
- Podziel zbiór treningowy na cechy (X, czyli X1-X64) i zmienną docelową (y, czyli class).
- Rozważ skalowanie danych numerycznych, ponieważ mimo że naiwny Bayes sam w sobie nie wymaga skalowania, może to pomóc w imputacji braków lub w interpretacji danych.

Klasyfikacja metodą Gausowskiego naiwnego Bayesa:

- Zbuduj model klasyfikatora **Gausowskiego naiwnego Bayesa** (GaussianNB), który zakłada, że cechy mają rozkład normalny.
- Wytrenuj model na przygotowanym zbiorze treningowym.
- Wykonaj predykcję prawdopodobieństw bankructwa dla firm ze zbioru bankructwa_test.csv.

Optymalizacja progu odcięcia i prezentacja wyników:

- Na podstawie przewidzianych prawdopodobieństw, **dopasuj próg odcięcia**, aby osiągnąć czułość (recall) na poziomie 0.95 dla klasy b'1' na danych treningowych/walidacyjnych.
- Zastosuj wyznaczony próg do predykcji klasy (b'0' lub b'1') dla firm ze zbioru bankructwa_test.csv.
- Utwórz plik b.csv zawierający wyłącznie kolumnę z przewidzianymi wartościami **class (b'0' lub b'1')** dla danych ze zbioru bankructwa_test.csv. Nazwa kolumny powinna być class. **Pamiętaj o odpowiednim sformatowaniu zmiennej class.**
- Przygotuj krótkie podsumowanie zawierające:

Rozwiązanie należy przestać w pliku jupyter notebook oraz pliku b.csv.