

Zadanie 1: Klasyfikacja przyznania kredytu metodą drzewa decyzyjnego

Opis zadania

Celem zadania jest zbudowanie modelu klasyfikacyjnego, który przewiduje, czy klientowi powinien zostać **przyznany kredyt (Y)**, czy **nie (N)**, na podstawie jego danych demograficznych i finansowych. Do klasyfikacji zostanie użyte **pojedyncze drzewo decyzyjne**. Model zostanie wytrenowany na zbiorze danych **kredyt.csv**, a następnie użyty do predykcji statusu kredytu dla klientów ze zbioru **kredyt_test.csv**. Kryterium oceny modelu będzie **accuracy score**.

Opis zbioru danych

Zbiór **kredyt.csv** zawiera **535 rekordów**, a **kredyt_test.csv** **81 rekordów**. Oba zbiory danych zawierają następujące zmienne:

Nazwa zmiennej	Opis
Loan_ID	Unikalny identyfikator kredytu (tekstowy)
Gender	Płeć klienta: Male, Female (nominalna)
Married	Status cywilny: Yes, No (nominalna, binarna)
Dependents	Liczba osób na utrzymaniu: 0, 1, 2, 3+ (nominalna, "3+" oznacza 3 lub więcej)
Education	Wykształcenie: Graduate, Not Graduate (nominalna, binarna)
Self_Employed	Status zatrudnienia: Yes, No (nominalna, binarna)
ApplicantIncome	Dochód wnioskodawcy (liczbowa)
CoapplicantIncome	Dochód współwnioskodawcy (liczbowa)
LoanAmount	Kwota kredytu (liczbowy)
Loan_Amount_Term	Okres spłaty kredytu w miesiącach (liczbowy, ograniczona liczba unikalnych wartości)
Credit_History	Historia kredytowa: 0.0 (brak/zła), 1.0 (dobra) (liczbowa, binarna)
Property_Area	Lokalizacja nieruchomości: Rural, Urban, Semiurban (nominalna, 3 wartości)
Loan_Status	Status przyznania kredytu: Y lub N (zmienna docelowa)

Zakres pracy

Przygotowanie danych:

- Załaduj zbiór danych kredyt.csv (dane treningowe) i kredyt_test.csv (dane do predykcji).
- Sprawdź czy istnieją brakujące wartości. W razie potrzeby usuń wiersze z brakującymi wartościami lub uzupełnij je.
- Przekształć zmienne kategoryczne na numeryczne (np. przy użyciu kodowania One-Hot Encoding lub Label Encoding, w zależności od charakteru zmiennej).
- Podziel zbiór treningowy na cechy (X) i zmienną docelową (y, czyli Loan_Status).

Klasyfikacja metodą drzewa decyzyjnego:

- Zbuduj model **pojedynczego drzewa decyzyjnego**.
- Wytrenuj model na przygotowanym zbiorze treningowym.
- Wykonaj predykcję statusu kredytu dla klientów ze zbioru kredyt_test.csv.

Prezentacja wyników:

- Utwórz plik k.csv zawierający wyłącznie kolumnę z przewidzianymi statusami kredytów dla danych ze zbioru kredyt_test.csv (bez indeksów). Nazwą kolumny powinna być Loan_Status.

Rozwiązanie należy przestać w pliku jupyter notebook oraz pliku k.csv.

Zadanie 2: Regresja cen pizzy metodą drzewa decyzyjnego

Opis zadania

Celem zadania jest zbudowanie modelu regresji, który przewiduje **cenę pizzy (price_cad)** na podstawie jej cech. Do predykcji ceny zostanie użyte **pojedyncze drzewo decyzyjne**. Model zostanie wytrenowany na zbiorze danych pizza.csv, a następnie użyty do predykcji cen dla pizz ze zbioru pizza_test.csv. Kryterium oceny modelu będzie **coefficient of determination (R-squared)**.

Opis zbioru danych

Zbiór **pizza.csv** zawiera **109 rekordów**, a **pizza_test.csv** **22 rekordy**. Oba zbiory danych zawierają następujące zmienne:

Nazwa zmiennej	Opis
Company	Nazwa firmy/restauracji: A, B, C, D, E (nominalna)
price_cad	Cena pizzy w CAD (tekstowa, ze znakiem \$, zmienna prognozowana)
Diameter	Średnica pizzy (tekstowa, z jednostką " inch")
Topping	Rodzaj dodatków (nominalna, kilkanaście wartości)
Variant	Wariant pizzy (nominalna, kilkanaście wartości)
Size	Rozmiar pizzy (kategoryczna tekstowa, 6 wartości)
extra_sauce	Czy jest dodatkowy sos: yes, no (binarna)
extra_cheese	Czy jest dodatkowy ser: yes, no (binarna)
extra_mushrooms	Czy są dodatkowe pieczarki: yes, no (binarna)

Uwaga: Zmienne price_cad i diameter są zapisane jako **tekstowe** i wymagają konwersji na **numeryczne**, usuwając odpowiednio znak \$ i słowo " inch".

Zakres pracy

Przygotowanie danych:

- Załaduj zbiór danych pizza.csv (dane treningowe) i pizza_test.csv (dane do predykcji).
- Sprawdź czy istnieją brakujące wartości. W razie potrzeby usuń wiersze z brakującymi wartościami lub uzupełnij je.
- Przekształć kolumny price_cad i diameter na typ numeryczny, usuwając niepotrzebne znaki i jednostki.
- Przekształć zmienne kategoryczne na numeryczne (np. przy użyciu kodowania One-Hot Encoding).
- Podziel zbiór treningowy na cechy (X) i zmienną docelową (y, czyli price_cad).

Regresja metodą drzewa decyzyjnego:

- Zbuduj model **pojedynczego drzewa decyzyjnego**.
- Wytrenuj model na przygotowanym zbiorze treningowym.
- Wykonaj predykcję cen dla pizz ze zbioru pizza_test.csv.

Prezentacja wyników:

- Utwórz plik p.csv zawierający wyłącznie kolumnę z przewidzianymi cenami pizzy dla danych ze zbioru pizza_test.csv (bez indeksów). Nazwą kolumny powinna być price_cad. Pamiętaj, że ceny muszą być **numeryczne** (bez znaku dolara).

Rozwiązanie należy przestać w pliku jupyter notebook oraz pliku p.csv.