


Regresja Logistyczna

Szymon Głab

Zmienna niezależna jest binarna



W regresji liniowej zmienne kategoryjne mogą być wśród zmiennych niezależnych, ale nie mogą być zmienną niezależną

$$y = b_0 + b_1 * x_1 + b_2 * \text{dummy}$$

regresja logistyczna vs. regresja liniowa

regresja logistyczna → decyzja TAK/NIE

regresja liniowa → przewidywanie wartości np. ceny

Model regresji logistycznej

Za pomocą regresji logistycznej można przewidzieć prawdopodobieństwo wystąpienia zdarzeń

Wejście $X = (x_1, x_2, \dots, x_k) \longrightarrow$ Prawdopodobieństwo $P(X)$

$$P(X) = \frac{\exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)}{1 + \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)}$$

$$P(X)(1 + \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)) = \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)$$

$$P(X) + P(X) \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k) = \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)$$

$$P(X) = \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k) - P(X) \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)$$

$$P(X) = \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)(1 - P(X))$$

Model regresji logitowej

$$\frac{P(X)}{1 - P(X)} = \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)$$

Przykład 1. Moneta symetryczna: $P(O) = 50\%$ i $P(R) = 50\%$.

$$\text{Szanse na wyrzucenie orła} = \frac{P(HEADS)}{P(TAILS)} = \frac{50\%}{50\%} = 1 : 1$$

Przykład 2. Kostka

$$\text{Szanse na wyrzucenie 6} = \frac{P(\{6\})}{P(\{1, 2, 3, 4, 5\})} = \frac{\frac{1}{6}}{\frac{5}{6}} = 1 : 5$$

Szanse zależą liniowo od zmiennych niezależnych

$$\text{odds} = \frac{P(X)}{1 - P(X)} = \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)$$

$$\log(\text{odds}) = \log\left(\frac{P(X)}{1 - P(X)}\right) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

$$\log(\text{odds}) = \beta^T \hat{X}$$

Tutaj β to wektor pionowy $(\beta_0, \dots, \beta_k)^T$, a $\hat{X}$ to wektor $(1, x_1, \dots, x_k)$. Później dla skrócenia zapisu będziemy pisać $\beta^T X$ zamiast $\beta^T \hat{X}$.

Interpretacja parametrów modelu

Zauważmy, że

$$\begin{aligned}\beta_1 &= [\beta_0 + \beta_1(x_1 + 1) + \beta_2 x_2 + \dots + \beta_k x_k] - [\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k] \\&= \log(\text{odds}(x_1 + 1, x_2, \dots, x_k)) - \log(\text{odds}(x_1, x_2, \dots, x_k)) \\&= \log \frac{\text{odds}(x_1 + 1, x_2, \dots, x_k)}{\text{odds}(x_1, x_2, \dots, x_k)}.\end{aligned}$$

Zatem

$$\frac{\text{odds}(x_1 + 1, x_2, \dots, x_k)}{\text{odds}(x_1, x_2, \dots, x_k)} = e^{\beta_1}$$

i w konsekwencji

$$\text{odds}(x_1 + 1, x_2, \dots, x_k) = e^{\beta_1} \text{odds}(x_1, x_2, \dots, x_k).$$

Oznacza to, że zwiększenie zmiennej x_1 o jedną jednostkę zwiększa e^{β_1} razy szansę na wystąpienie modelowanego zdarzenia.

Dobieranie parametrów $\beta_0, \dots, \beta_k$

Założmy, że $(X^{(1)}, y^{(1)}), \dots, (X^{(n)}, y^{(n)})$ są obserwowanymi wartościami. Wtedy $X^{(i)}$ to k -wymiarowy wektor, a $y^{(i)} \in \{0, 1\}$.

Parametry $\beta = (\beta_0, \dots, \beta_k)$ są wyznaczone metodą największej wiarygodności, tzn. maksymalizujemy wyrażenie

$$L(\beta) = \prod_{i=1}^n P(Y = y^{(i)} | X = X^{(i)}; \beta),$$

co jest równoważne maksymalizacji

$$\ell(\beta) = \log\left(\prod_{i=1}^n P(Y = y^{(i)} | X = X^{(i)}; \beta)\right) = \sum_{i=1}^n \log P(Y = y^{(i)} | X = X^{(i)}; \beta).$$

Dobieranie parametrów $\beta_0, \dots, \beta_k$

$$\ell(\beta) = \sum_{i=1}^n \log P(Y = y^{(i)} | X = X^{(i)}; \beta).$$

Przez $p_i(\beta)$ oznaczmy $P(Y = 1 | X = X^{(i)}; \beta)$. Wówczas

$$P(Y = y^{(i)} | X = X^{(i)}; \beta) = p_i(\beta)^{y^{(i)}} (1 - p_i(\beta))^{1-y^{(i)}}$$

Istotnie, jeśli $y^{(i)} = 1$, to $(1 - p_i(\beta))^{1-y^{(i)}} = 1$ i iloczyn redukuje się do $p_i(\beta)$; a jeśli $y^{(i)} = 0$, to $p_i(\beta)^{y^{(i)}} = 1$ i iloczyn redukuje się do $1 - p_i(\beta)$. Zatem

$$\begin{aligned} \log P(Y = y^{(i)} | X = X^{(i)}; \beta) &= \log(p_i(\beta)^{y^{(i)}} (1 - p_i(\beta))^{1-y^{(i)}}) = \\ &= y^{(i)} \log p_i(\beta) + (1 - y^{(i)}) \log(1 - p_i(\beta)) \end{aligned}$$

Dobieranie parametrów $\beta_0, \dots, \beta_k$

$$\ell(\beta) = \sum_{i=1}^n \log P(Y = y^{(i)} | X = X^{(i)}; \beta).$$

Przez $p_i(\beta)$ oznaczmy $P(Y = 1 | X = X^{(i)}; \beta)$. Wówczas

$$P(Y = y^{(i)} | X = X^{(i)}; \beta) = p_i(\beta)^{y^{(i)}} (1 - p_i(\beta))^{1-y^{(i)}}$$

Istotnie, jeśli $y^{(i)} = 1$, to $(1 - p_i(\beta))^{1-y^{(i)}} = 1$ i iloczyn redukuje się do $p_i(\beta)$; a jeśli $y^{(i)} = 0$, to $p_i(\beta)^{y^{(i)}} = 1$ i iloczyn redukuje się do $1 - p_i(\beta)$. Zatem

$$\begin{aligned} \log P(Y = y^{(i)} | X = X^{(i)}; \beta) &= \log(p_i(\beta)^{y^{(i)}} (1 - p_i(\beta))^{1-y^{(i)}}) = \\ &= y^{(i)} \log p_i(\beta) + (1 - y^{(i)}) \log(1 - p_i(\beta)) \end{aligned}$$

Dobieranie parametrów $\beta_0, \dots, \beta_k$

$$\ell(\beta) = \sum_{i=1}^n \log P(Y = y^{(i)} | X = X^{(i)}; \beta) =$$

$$\sum_{i=1}^n \left(y^{(i)} \log p_i(\beta) + (1 - y^{(i)}) \log(1 - p_i(\beta)) \right) =$$

$$\sum_{i=1}^n \left(y^{(i)} \log \frac{\exp(\beta^T X^{(i)})}{1 + \exp(\beta^T X^{(i)})} + (1 - y^{(i)}) \log \left(1 - \frac{\exp(\beta^T X^{(i)})}{1 + \exp(\beta^T X^{(i)})} \right) \right)$$

Ostatecznie parametry $\beta_0, \beta_1, \dots, \beta_k$ są dobierane tak, by zminimalizować powyższe wyrażenie.