


Maszyna wektorów podpierających. SVM (Support Vector Machine)

Szymon Głąb


Separowanie punktów za pomocą hiperpłaszczyzny




Dane można rozdzielić wieloma prostymi (hiperpłaszczyznami). Potrzebne jest kryterium pozwalające wybrać odpowiednią.

Margines

Tym kryterium jest szerokość tzw. marginesu.




Tym kryterium jest szerokość tzw. marginesu.



Założmy, że dwie grupy są liniowo separowalne. Dla dowolnej prostej (hiperpłaszczyzny) P_0 oddzielającej klasy znajdujemy dwie proste równoległe dla niej P_1 i P_2 , które nadal separują klasy, ale pewne punkty z klasy 1 leżą na P_1 , a pewne punkty z klasy 2 leżą na P_2 . **Margines** to odległość między P_1 i P_2 .

Kryterium wyboru hiperpłaszczyzny separującej

Tym kryterium jest szerokość tzw. marginesu.



Kryterium dla 2 klas liniowo separowalnych

Najlepsza prosta (hiperpłaszczyzna) separująca klasy, to ta dla której margines jest największy, a ona sama leży pośrodku brzegów marginesów.

Równanie hiperpłaszczyzny

Niech w będzie niezerowym wektorem w $\mathbb{R}^p$, a $y \in \mathbb{R}^p$ dowolnym punktem.

Równanie hiperpłaszczyzny

Niech w będzie niezerowym wektorem w $\mathbb{R}^p$, a $y \in \mathbb{R}^p$ dowolnym punktem. Hiperpłaszczyzna przechodząca przez punkt y prostopadła do w składa się z punktów $x \in \mathbb{R}^d$ takich, że

$$w \cdot (x - y) = 0$$

Równanie hiperpłaszczyzny

Niech w będzie niezerowym wektorem w $\mathbb{R}^p$, a $y \in \mathbb{R}^p$ dowolnym punktem. Hiperpłaszczyzna przechodząca przez punkt y prostopadła do w składa się z punktów $x \in \mathbb{R}^d$ takich, że

$$w \cdot (x - y) = 0$$

$$w \cdot x - w \cdot y = 0$$

Równanie hiperpłaszczyzny

Niech w będzie niezerowym wektorem w $\mathbb{R}^p$, a $y \in \mathbb{R}^p$ dowolnym punktem. Hiperpłaszczyzna przechodząca przez punkt y prostopadła do w składa się z punktów $x \in \mathbb{R}^d$ takich, że

$$w \cdot (x - y) = 0$$

$$w \cdot x - w \cdot y = 0$$

Hiperpłaszczyzna w przestrzeni $\mathbb{R}^p$.

Niech w będzie niezerowym wektorem w $\mathbb{R}^p$ oraz $b \in \mathbb{R}^p$. Hiperpłaszczyzną w $\mathbb{R}^p$ nazywamy zbiór

$$\{x \in \mathbb{R}^p : w \cdot x + b = 0\}.$$

Iloczyn skalarny w literaturze

Często można spotkać następującą notację. Wektory $\mathbf{w} \in \mathbb{R}^p$ traktuje się jako wektory pionowe

$$\mathbf{w} = \begin{bmatrix} w_1 \\ w_2 \\ \dots \\ w_p \end{bmatrix} = [w_1 \ w_2 \ \dots \ w_p]^T$$

Iloczyn skalarny wektorów $\mathbf{w}, \mathbf{x} \in \mathbb{R}^p$ ma postać

$$\mathbf{w}^T \mathbf{x} = [w_1 \ w_2 \ \dots \ w_p] \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_p \end{bmatrix} = \sum_{i=1}^p w_i x_i.$$

Klasyfikacja binarna metodą SVM

Założmy, że mamy dwie klasy.

Klasyfikacja binarna metodą SVM

Założmy, że mamy dwie klasy. Jedna z nich będzie klasą *dodatnią*, a druga *ujemną*. Etykiety klas oznaczamy przez ± 1 .

Założmy, że mamy dwie klasy. Jedna z nich będzie klasą *dodatnią*, a druga *ujemną*. Etykiety klas oznaczamy przez ± 1 . Jeśli te klasy dają się liniowo odseparować, a prosta $w^T x + b = 0$ to optymalna prosta (spełniająca kryterium największego marginesu), to nową obserwację $z \in \mathbb{R}^p$ klasyfikujemy następująco:

$$\text{sgn}(w^T z + b)$$

Odległość punktu od hiperpłaszczyzny

Założmy, że $w^T x + b = 0$ jest hiperpłaszczyzną taką, że $\|w\| = 1$. Niech z będzie dowolnym punktem.

Odległość punktu od hiperpłaszczyzny

Założmy, że $w^T x + b = 0$ jest hiperpłaszczyzną taką, że $\|w\| = 1$. Niech z będzie dowolnym punktem. Wybierzmy dowolny punkt x na prostej. Wówczas dla $\theta = \angle(w, z - x)$

$$w^T(z - x) = \|w\| \cdot \|z - x\| \cdot \cos \theta = \|z - x\| \cdot \cos \theta$$

jest odległością między z i rzutem z na hiperpłaszczyznę, czyli odległością z od niej (z dokładnością do znaku).

Odległość punktu od hiperpłaszczyzny

Założmy, że $w^T x + b = 0$ jest hiperpłaszczyzną taką, że $\|w\| = 1$. Niech z będzie dowolnym punktem. Wybierzmy dowolny punkt x na prostej. Wówczas dla $\theta = \angle(w, z - x)$

$$w^T(z - x) = \|w\| \cdot \|z - x\| \cdot \cos \theta = \|z - x\| \cdot \cos \theta$$

jest odległością między z i rzutem z na hiperpłaszczyznę, czyli odległością z od niej (z dokładnością do znaku). Skoro $w^T x + b = 0$, to

$$w^T(z - x) + 0 = w^T(z - x) + w^T x + b = w^T z + b$$

Odległość punktu od hiperpłaszczyzny

Założmy, że $w^T x + b = 0$ jest hiperpłaszczyzną taką, że $\|w\| = 1$. Niech z będzie dowolnym punktem. Wybierzmy dowolny punkt x na prostej. Wówczas dla $\theta = \angle(w, z - x)$

$$w^T(z - x) = \|w\| \cdot \|z - x\| \cdot \cos \theta = \|z - x\| \cdot \cos \theta$$

jest odległością między z i rzutem z na hiperpłaszczyznę, czyli odległością z od niej (z dokładnością do znaku). Skoro $w^T x + b = 0$, to

$$w^T(z - x) + 0 = w^T(z - x) + w^T x + b = w^T z + b$$

Zatem dla dowolnej hiperpłaszczyzny $w^T x + b = 0$ i punktu z odległość jest dana wzorem

$$\frac{|w^T z + b|}{\|w\|}.$$

Hiperpłaszczyzna dzieli przestrzeń na dwie części

Niech $w^T x + b = 0$ będzie równaniem hiperpłaszczyzny. Dzieli ona przestrzeń na dwa obszary: $\{x \in \mathbb{R}^p : w^T x + b > 0\}$ i $\{x \in \mathbb{R}^p : w^T x + b < 0\}$.

Hiperpłaszczyzna dzieli przestrzeń na dwie części

Niech $w^T x + b = 0$ będzie równaniem hiperpłaszczyzny. Dzieli ona przestrzeń na dwa obszary: $\{x \in \mathbb{R}^p : w^T x + b > 0\}$ i $\{x \in \mathbb{R}^p : w^T x + b < 0\}$. Jeśli hiperpłaszczyzna jest tak dobrana, że separuje dwie klasy zbioru danych, to jedna klasa jest zawarta w $\{x \in \mathbb{R}^p : w^T x + b > 0\}$ a druga w $\{x \in \mathbb{R}^p : w^T x + b < 0\}$.

Hiperpłaszczyzna dzieli przestrzeń na dwie części

Niech $w^T x + b = 0$ będzie równaniem hiperpłaszczyzny. Dzieli ona przestrzeń na dwa obszary: $\{x \in \mathbb{R}^p : w^T x + b > 0\}$ i $\{x \in \mathbb{R}^p : w^T x + b < 0\}$. Jeśli hiperpłaszczyzna jest tak dobrana, że separuje dwie klasy zbioru danych, to jedna klasa jest zawarta w $\{x \in \mathbb{R}^p : w^T x + b > 0\}$ a druga w $\{x \in \mathbb{R}^p : w^T x + b < 0\}$. Skoro $y_i = \pm 1$, to ten fakt że punkty danych x_i i etykiety y_i mają ten sam znak zapisujemy

$$y_i(w^T x_i + b) > 0.$$

Hiperpłaszczyzna dzieli przestrzeń na dwie części

Niech $w^T x + b = 0$ będzie równaniem hiperpłaszczyzny. Dzieli ona przestrzeń na dwa obszary: $\{x \in \mathbb{R}^p : w^T x + b > 0\}$ i $\{x \in \mathbb{R}^p : w^T x + b < 0\}$. Jeśli hiperpłaszczyzna jest tak dobrana, że separuje dwie klasy zbioru danych, to jedna klasa jest zawarta w $\{x \in \mathbb{R}^p : w^T x + b > 0\}$ a druga w $\{x \in \mathbb{R}^p : w^T x + b < 0\}$. Skoro $y_i = \pm 1$, to ten fakt że punkty danych x_i i etykiety y_i mają ten sam znak zapisujemy

$$y_i(w^T x_i + b) > 0.$$

Równoważnie

$$\text{sgn}((w^T x_i + b)) = y_i$$

Dla takiej hiperpłaszczyzny reguła decyzyjna SVM działa!

Problem optymalizacyjny dla SVM

Jeśli $y_i(w^T x_i + b) > 0$ dla wszystkich, to

$$\min_i \frac{y_i(w^T x_i + b)}{\|w\|}$$

jest marginesem.

Problem optymalizacyjny dla SVM

Jeśli $y_i(w^T x_i + b) > 0$ dla wszystkich, to

$$\min_i \frac{y_i(w^T x_i + b)}{\|w\|}$$

jest marginesem. Wówczas hiperpłaszczyzna o największym marginesie, to ta będąca rozwiązaniem problemu optymalizacyjnego

$$\max_{w,b} \min_i \frac{y_i(w^T x_i + b)}{\|w\|} = \max_{w,b} \frac{1}{\|w\|} \min_i y_i(w^T x_i + b)$$

Problem optymalizacyjny dla SVM

Okazuje się, że znalezienie w i b , dla których maksymalizuje się wyrażenie

$$\frac{1}{\|w\|} \min_i y_i (w^T x_i + b)$$

jest równoważne z minimalizacją

$$\frac{1}{2} \|w\|^2$$

przy warunkach


$$y_i (w^T x_i + b) \geq 1.$$

To jest wypukły kwadratowy problem optymalizacyjny, który ma dokładnie jedno rozwiązanie.

A co gdy klasy nie są liniowo separowalne?

Liniowa separowalność klas nie zdarza się często.


Potrzebujemy metody, która zadziała, nawet jeśli klasy nie są liniowo separowalne.



A co gdy klasy nie są liniowo separowalne?

Liniowa separowalność klas nie zdarza się często.

Potrzebujemy metody, która zadziała, nawet jeśli klasy nie są liniowo separowalne.



Wówczas minimalizujemy wyrażenie

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

przy warunkach

$$y_i(w^T x_i + b) \geq 1 - \xi_i \text{ oraz } \xi_i \geq 0.$$


A co gdy klasy nie są liniowo separowalne?

W problemie optymalizacyjnym

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

przy warunkach $y_i(w^T x_i + b) \geq 1 - \xi_i$ oraz $\xi_i \geq 0$, ξ_i odpowiadają za błędy, a hiperparametr $C > 0$ odpowiada za to w jakim stopniu *zmiękczamy (soften)* możliwe rozwiązanie. Im mniejsze $C > 0$, tym większe błędy ξ_i są dopuszczalne.

Kernel trick



Idea polega na przejściu do wyższego wymiaru $x \mapsto \varphi(x)$ tak by klasy dały się liniowo odseparować. Np.

$$\varphi(x_1, x_2) = (x_1^2, x_2^2, \sqrt{2}x_1x_2)$$

Wektory $x \in \mathbb{R}^p$ są przekształcane do przestrzeni $\varphi(x) = [\varphi_1(x), \dots, \varphi_M(x)] \in \mathbb{R}^M$. Rozwiązać należy problem optymalizacyjny

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

przy warunkach $y_i(w^T \varphi(x_i) + b) \geq 1 - \xi_i$ oraz $\xi_i \geq 0$.

Wektory $x \in \mathbb{R}^p$ są przekształcane do przestrzeni $\varphi(x) = [\varphi_1(x), \dots, \varphi_M(x)] \in \mathbb{R}^M$. Rozwiązać należy problem optymalizacyjny

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

przy warunkach $y_i(w^T \varphi(x_i) + b) \geq 1 - \xi_i$ oraz $\xi_i \geq 0$. Do rozwiązania tego problemu wystarczająca jest znajomość funkcji (kernel) $K(x, x') = \varphi(x)^T \varphi(x')$.

W sklearn funkcja jądrowa (kernel function) może być jedną z następujących:

W sklearn funkcja jądrowa (kernel function) może być jedną z następujących:

- **linear**: $\langle x, x' \rangle$

Funkcje jądrowe w sklearn

W sklearn funkcja jądrowa (kernel function) może być jedną z następujących:

- **linear**: $\langle x, x' \rangle$
- **polynomial**: $(\gamma \langle x, x' \rangle + r)^d$, gdzie d definiuje się za pomocą parameteru **degree**, a r przez **coef0**.

Funkcje jądrowe w sklearn

W sklearn funkcja jądrowa (kernel function) może być jedną z następujących:

- **linear**: $\langle x, x' \rangle$
- **polynomial**: $(\gamma \langle x, x' \rangle + r)^d$, gdzie d definiuje się za pomocą parameteru **degree**, a r przez **coef0**.
- **rbf**: $\exp(-\gamma \|x - x'\|^2)$, gdzie γ definiuje się za pomocą parameteru **gamma** > 0 .

Funkcje jądro w sklearn

W sklearn funkcja jądro (kernel function) może być jedną z następujących:

- **linear**: $\langle x, x' \rangle$
- **polynomial**: $(\gamma \langle x, x' \rangle + r)^d$, gdzie d definiuje się za pomocą parameteru **degree**, a r przez **coef0**.
- **rbf**: $\exp(-\gamma \|x - x'\|^2)$, gdzie γ definiuje się za pomocą parameteru **gamma** > 0 .
- **sigmoid** $\tanh(\gamma \langle x, x' \rangle + r)$, gdzie r definiuje się za pomocą parametru **coef0**.