


Las losowy

(ensemble models)

Modele zespołowe:

Dzieła są słabymi klasyfikatorami (przetrenowane, mało dokładne)

Idea: połączmy modele w grupę modeli

Model zespołowy = panel ekspertów

Jeżeli mamy 2 ekspertów, z których każdy ma takie samo zdanie, to po co nam 2? Jeden jest zbędny.

Dane mają być niekorelowane

Problem: Drzewa decyzyjne są deterministyczne

Bagging - worek?

B - liczba modeli w modelu zespołowym ^{bootstrap}

① Losujemy ze zwracaniem B zbiorów danych o tej samej liczbie więcej co model wejściowy

② Trenujemy model na każdym z B zbiorów

③ Uzyskujemy prognozę zespołową

- klasyfikacja = głosowanie
- regresja = średnia

(out-of-bag)

OBB score - losujemy ze zwracaniem (klasyfikacji)

62% - 64,5%

in-the-bag

out-of-bag

$M_1 \dots M_B$ budowane na $S_1, \dots, S_B$. Ustalmy wiersz r

① $M_r = \{M_i : r \notin S_i\}$

② Stosujemy model M_r do wiersza r i wyliczamy predykcję

③ Predykcja vs. prawdziwa wartość

④ Na podstawie ② i ③ wyliczamy dokładność

Las losowy (klasyfikacji)

Las losowy = bagging dla drzew decyzyjnych + losowy dobór kolumn/cech

Hiperparametry lasu losowego

n_estimators - liczba drzew

OBB-score: gdy się stabilizuje, to uzyskaliśmy właściwą liczbę drzew

Hiperparametry do dostrajania (od drzew)

max_depth, min_sample_leaf, max_sample_split, splitting_rule

Parametry zespołowe

max_features (liczba kolumn, domyślnie)

max_samples - liczba wierszy losowo do drzewa (domyślnie wszystkie)

bootstrap (TRUE, domyślnie)

oob_score (FALSE, domyślnie)

splitting_rule

- bez, domyślnie
- random → zmniejsza się korelacja drzew
- ↳ Extremely Randomize Trees

class_weight

- None domyślnie
- balanced ← warto?
- balanced_subsample

Grid Search CV vs. Randomize Search CV

↳ **Optuna**

Feature importance

uśrednianie feature importance dla drzew lasu.

Dotarcie losowej kolumny

↳ jej znaczenie można użyć jako poziom 0

F.I. vs. permutation importance variable importance measure.

Las Losowy dla regresji:

Parametry rekomendowane

n_estimators = 1000

max_depth = 15

min_sample_leaf = 50

max_feature = $\frac{1}{3}$

na końcu też uśredniamy.

Zalety i Wady Lasu Losowego

Zalety

- odporność na overfitting
- znajdowanie nieliniowych zależności
- mało pre-processingu
- radzi sobie z odstającymi wartościami

LL działa nie dlatego, że drzewa są takie dobre,
tylko dlatego, że są różne.

Wady

- długi model (pamięć + czas)
- mała interpretowalność

Naiwny klasyfikator bayesowski:

$P(A|B) = \frac{P(A \cap B)}{P(B)}$

	M	K	
zaszyc.	32	48	80
n.e. zaszyc.	8	12	20
	40	60	100


$P(Z|M) = \frac{P(Z \cap M)}{P(M)} = \frac{\frac{32}{100}}{\frac{40}{100}} = 0,8 = P(Z)$

$P(Z|M) = \frac{P(Z \cap M)}{P(M)} = P(Z)$

$P(Z \cap M) = P(Z) \cdot P(M)$

$P(A|B) = \frac{P(A \cap B)}{P(B)}$
 $P(B|A) = \frac{P(B \cap A)}{P(A)}$

$P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$
 $P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$



Losowo wybranej osobie udaje się rozwiązać problem.
Czy to M czy K?

$P(M|S) = \frac{0,6 \cdot 0,6}{P(S)} = \frac{0,36}{P(S)}$

$P(K|S) = \frac{0,7 \cdot 0,4}{P(S)} = \frac{0,28}{P(S)}$

1000 owoców (3 rodzaje : pomarańcze, banany, inne)
długość (t,n) , słodkie (t,n) , żółte (t,n)

	Owoc (Y)	długi (X ₁)	słodki (X ₂)	żółty (X ₃)
1	p	0	1	0
2	b	1	0	1
3	b	1	1	1

Y	$X_1=1 \mid X_1=0$	$X_2=1 \mid X_2=0$	$X_3=1 \mid X_3=0$	
Owoc	długi	słodki	żółty	
banan	400 100	350 150	450 50	500
pom	0 300	150 150	300 0	300
inne	100 100	150 50	50 150	200
	500	500	650	350

mamy owoc: długi, niesłodki, żółty

$P(Y=banana | X_1=1, X_2=0, X_3=1)$
 $P(Y=pom. | \text{---} // \text{---})$
 $P(Y=inne | \text{---} // \text{---})$

$\left. \begin{matrix} \\ \\ \end{matrix} \right\} \max$

$P(Y|X_1, X_2, X_3) = \frac{P(Y \cap X_1 \cap X_2 \cap X_3)}{P(X_1 \cap X_2 \cap X_3)}$

$P(X_1 \cap X_2 \cap X_3 \cap Y) = P(X_1 | X_2 \cap X_3 \cap Y) \cdot P(X_2 \cap X_3 \cap Y) = P(X_1 | X_2, X_3, Y) \cdot P(X_2 | X_3 \cap Y) \cdot P(X_3 | Y) \cdot P(Y)$

Naiwność - zakładamy, że cechy X_i są niezależne

$P(Y | X_1 \cap X_2 \cap X_3) = \frac{P(X_1|Y) \cdot P(X_2|Y) \cdot P(X_3|Y) \cdot P(Y)}{P(X_1 \cap X_2 \cap X_3)}$

$P(Y=banana | X_1=1, X_2=0, X_3=1) = 0,4 \cdot 0,15 \cdot 0,45 \cdot 0,5 \rightarrow \max$
 $P(Y=pom. | \text{---} // \text{---}) = 0$
 $P(Y=inne | \text{---} // \text{---}) = 0,1 \cdot 0,15 \cdot 0,05 \cdot 0,2$

Model :

$P(Y=c_k | X_1, \dots, X_n) \propto P(Y=c_k) \prod_{i=1}^n P(X_i | Y=c_k)$ ↖ ilość' cech

Klasyfikator

$\hat{Y} = \operatorname{argmax}_{k \in \{1, \dots, K\}} P(Y=c_k) \cdot \prod_{i=1}^n P(X_i | Y=c_k)$

$\log(P(Y=c_k)) + \sum_{i=1}^n \log(P(X_i | Y=c_k))$

X₁ ∩ Y=c_k ↔ ustawiamy 1

Gaussowski naiwny Bayes

Y na $c_1, \dots, c_m$ kategorie

$X_1, \dots, X_n$ są wsłt

$X_i | Y = c_k \rightarrow$ rozkład normalny

$$f_i(v | Y = c_k) = \frac{1}{\sqrt{2\pi}\sigma_{k,i}} \exp\left(-\frac{(v - \mu_{k,i})^2}{2\sigma_{k,i}^2}\right)$$

$\mu_{k,i}$ średnia z próby dla X_i przy $y = c_k$
 $\sigma_{k,i}$ wariancja

$$\hat{Y} = \underset{k=1, \dots, m}{\operatorname{argmax}} P(Y=c_k) \cdot \prod_{i=1}^n f_i(v_i | Y=c_k) \quad (v_1, \dots, v_n)$$

S - spam $\neg S$ - nie spam

B - zawiera słowo 'bitcoin'

$$P(S|B) = \frac{P(B|S) \cdot P(S)}{P(B)} = \frac{P(B|S) \cdot P(S)}{P(B|S) \cdot P(S) + P(B|\neg S) \cdot P(\neg S)}$$

Jeżeli $P(S) = P(\neg S) = 0,5$ to,

$$\frac{P(B|S)}{P(B|S) + P(B|\neg S)} \quad \begin{array}{l} P(B|S) = 0,5 \\ P(B|\neg S) = 0,01 \end{array}$$

$$P(S|B) = \frac{0,5}{0,5 + 0,01} = 98\% \quad P$$

$$P(\neg S|B) = \frac{0,01}{0,5 + 0,01} = 2\%$$

$$D = \{w_1, w_2, \dots\} = \{\text{'bitcoin'}, \text{'rolex'}, \text{'sex'}, \text{'dear'}, \text{'attach'} \dots\}$$

$X_i = 1$ gdy wiadomość zawiera słowo w_i

$$\text{naiwność: } P(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n P(X_i = x_i)$$



$$P(S | X_1 = x_1, \dots, X_n = x_n) = \frac{\prod_{i=1}^n P(X_i = x_i | S)}{\prod_{i=1}^n P(X_i = x_i | S) + \prod_{i=1}^n P(X_i = x_i | \neg S)}$$

$$\sum_{i=1}^n \log(P(X_i = x_i | S)) > \sum_{i=1}^n \log(P(X_i = x_i | \neg S)) - \text{klasujemy jako spam.}$$

$w_i = \text{'bitcoin'}$

$$P(X_i = 1 | S) = \frac{1 + \text{ile razy w spamie występuje słowo 'bitcoin'}}{1 + \text{ilość spamu}}$$

Regresja logistyczna (klasyfikacja)



$y \in \{0, 1\}$
n. y_i

Model regresji logistycznej - klasyfikacja binarna

$X = (x_1, \dots, x_k) \longrightarrow$ prawd. $P(X)$, że $Y=1$
 $P(Y=1|X=x)$

$$P(x) = \frac{\exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)}{1 + \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)} = \frac{\exp(\beta_0 + \beta \cdot x)}{1 + \exp(\beta_0 + \beta \cdot x)}$$

iloczyn skalarny $\beta = (\beta_1, \beta_2, \dots, \beta_k)$
 $x = (x_1, x_2, \dots, x_k)$
 $\beta^T x$

$$P(x)(1 + \exp(\dots)) = \exp(\dots)$$

$$p(x) = \exp(\dots)(1 - p(x))$$

$$\frac{p(x)}{1 - p(x)} = \exp(\dots) \Rightarrow \ln \frac{p(x)}{1 - p(x)} = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

odds / szansa

log szans zależy liniowo od zmiennych zależnych

K - liczba klas (w problemie klasyfikacji)

$$\ln \frac{P(Y=1|X=x)}{P(Y=k|X=x)} = \beta_{10} + \beta_1^T x$$

$$\ln \frac{P(Y=2|X=x)}{P(Y=k|X=x)} = \beta_{20} + \beta_2^T x$$

$\vdots$

$$\ln \frac{P(Y=k-1|X=x)}{P(Y=k|X=x)} = \beta_{(k-1)0} + \beta_{(k-1)}^T x$$

$$P_k(x) = \frac{\exp(\beta_{k0} + \beta_k^T x)}{\sum_{l=1}^{K-1} \exp(\beta_{l0} + \beta_l^T x)}$$

sprawdzić czemu do ostatniej!

Szanse:

$$1. \text{ Szansa na wypadnięcie orła } \frac{P(D)}{P(R)} = \frac{P(D)}{1 - P(D)} = 1$$

$$2. \text{ Szansa że w rzucie kostką wypadnie 6 } \frac{P(\{6\})}{P(\{1, \dots, 6\})} = \frac{\frac{1}{6}}{\frac{6}{6}} = \frac{1}{6}$$

$$\text{szansa} \in (0, +\infty)$$

$$\log(\text{szansa}) \in (-\infty, +\infty)$$

$$\text{Cena samochodu} = A_0 + A_1 \text{rocznik} + A_2 \text{BMW} + A_3 \text{Audi}$$

$$\text{model} = \text{BMW}, \text{Audi}, \text{VW}$$

Interpretacja parametrów modelu

$$\beta_1 = [\beta_0 + \beta_1(x_1+1) + \beta_2 x_2 + \dots + \beta_k x_k] - [\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k] = \ln \text{odds}(x_1+1, x_2, \dots, x_k) - \ln \text{odds}(x_1, x_2, \dots, x_k) =$$

$$= \ln \frac{\text{odds}(x_1+1, x_2, \dots, x_k)}{\text{odds}(x_1, x_2, \dots, x_k)}$$

$$\frac{\text{odds}(x_1+1, x_2, \dots, x_k)}{\text{odds}(x_1, x_2, \dots, x_k)} = e^{\beta_1}$$

$Y=1$ - rak płuc, $Y=0$ - brak raka płuc

x_1 = średnia liczba wypalanych papierosów

x_2 = długość palenia

x_3 = płeć

stats. models $\rightarrow$ wyliczamy predykcje w 95% żeby zobaczyć czy x_k jest istotny

using $\hat{y}$ nie istotny, bootstrapping

$$(X^{(1)}, y^{(1)}), \dots, (X^{(n)}, y^{(n)}) \quad y^{(i)} \in \{0, 1\}$$

$\beta = (\beta_0, \dots, \beta_k)$ Maksymalizujemy wiarygodności

$$L(\beta) = \prod_{i=1}^n P(Y=y^{(i)} | X=X^{(i)}; \beta)$$

$$l(\beta) = \sum_{i=1}^n \ln(P(Y=y^{(i)} | X=X^{(i)}; \beta))$$

$$P_i(\beta) = P(Y=1 | X=X^{(i)}; \beta)$$

$$P(Y=y^{(i)} | X=X^{(i)}; \beta) = P_i(\beta)^{y^{(i)}} (1 - P_i(\beta))^{y^{(i)}-1}$$

$$\ln(P(Y=y^{(i)} | X=X^{(i)}; \beta)) = y^{(i)} \ln P_i(\beta) + (1 - y^{(i)}) \ln(1 - P_i(\beta))$$

$$l(\beta) = \sum_{i=1}^n (y^{(i)} \ln p_i(\beta) + (1 - y^{(i)}) \ln(1 - p_i(\beta))) = \sum_{i=1}^n y^{(i)} \ln \left(\frac{\exp(\beta^T x^{(i)})}{1 + \exp(\beta^T x^{(i)})} \right) + (1 - y^{(i)}) \ln \left(1 - \frac{\exp(\beta^T x^{(i)})}{1 + \exp(\beta^T x^{(i)})} \right)$$

Regulacja i wagi

Wyznaczamy $\beta_0, \beta_1, \dots, \beta_k$ tak, że

$$\max_{\beta_0, \dots, \beta_k} \left[\frac{1}{S} \sum_{i=1}^n s_i \left(y^{(i)} \ln \frac{\exp(\beta^T x^{(i)})}{1 + \exp(\beta^T x^{(i)})} + (1 - y^{(i)}) \ln \left(1 - \frac{\exp(\beta^T x^{(i)})}{1 + \exp(\beta^T x^{(i)})} \right) \right) \right] + \frac{r(\beta)}{S \cdot C}$$

s_i - wagi obserwacji $x^{(i)}$ (domyślnie $s_i = 1$) $S = \sum_{i=1}^n s_i$

class_weight = 'balanced' ← wzmocnia obserwacje, których jest mniej

(- stała ($C=1$) $C = np.inf$ - bez regularyzacji

$r(\beta)$ - regularyzacja

$$l_1 \quad \|\beta\|_1 = \sum |\beta_i|$$

$$l_2 \quad \frac{1}{2} \|\beta\|_2^2 = \frac{1}{2} \beta^T \beta = \frac{1}{2} \sum \beta_i^2$$

$$\text{Elastic Net} \quad \frac{1-\alpha}{2} \beta^T \beta + \alpha \|\beta\|_1$$

$$l_1\text{-ratio} = 1 \Rightarrow l_1$$

$$= 0 \Rightarrow l_2 \text{ (domyślnie)}$$

regularyzacja $l_1 \Rightarrow$ wiele $\beta_i = 0$

Logistic Regression CV

Tuning C i l_1 -ratio

$$C=10 \xrightarrow{\text{domyślnie}} 10^{-4}, 10^{-3}, \dots, 10^4$$